

# Econometría 1 - Actividad 7

## Variables Instrumentales

### Ejercicios 1 y 2: Teoría y Derivaciones

División de Economía - CDE

Dr. Francisco Cabrera

## 1. EJERCICIO 1: Efecto de PC sobre GPA

### 1.1. Ejercicio 1a: Endogeneidad de PC

#### El modelo

Consideramos el modelo:

$$\text{GPA}_i = \beta_0 + \beta_1 \text{PC}_i + u_i \quad (1)$$

donde:

- $\text{GPA}_i$  = promedio de calificaciones del estudiante  $i$
- $\text{PC}_i$  = variable binaria (1 si tiene computadora, 0 si no)
- $u_i$  = término de error (incluye todas las variables no observadas)

#### El problema de endogeneidad

**Supuesto de Exogeneidad (necesario para MCO):**

$$E(u_i | \text{PC}_i) = 0 \quad \Leftrightarrow \quad \text{Cov}(\text{PC}_i, u_i) = 0 \quad (2)$$

**¿Por qué PC está correlacionada con  $u$ ?**

La variable PC es **endógena** porque está correlacionada con variables no observadas en  $u_i$ :

$$\text{Cov}(\text{PC}_i, u_i) \neq 0 \quad (3)$$

**Fuentes de endogeneidad:**

1. **Habilidad no observada** ( $\text{ability}_i \in u_i$ ):

$$\begin{aligned} \text{PC}_i &= f(\text{ability}_i, \dots) \\ \text{GPA}_i &= g(\text{ability}_i, \dots) \end{aligned} \quad (4)$$

Estudiantes más hábiles  $\Rightarrow$  mayor probabilidad de tener PC y mayor GPA.

2. **Antecedentes familiares** ( $\text{family}_i \in u_i$ ):

$$\begin{aligned} \text{PC}_i &= f(\text{family}_i, \dots) \\ \text{GPA}_i &= g(\text{family}_i, \dots) \end{aligned} \quad (5)$$

Mejor ambiente familiar  $\Rightarrow$  mayor probabilidad de tener PC y mayor GPA.

3. **Motivación no observada** ( $\text{motivation}_i \in u_i$ ):

$$\begin{aligned} \text{PC}_i &= f(\text{motivation}_i, \dots) \\ \text{GPA}_i &= g(\text{motivation}_i, \dots) \end{aligned} \quad (6)$$

Mayor motivación  $\Rightarrow$  buscar herramientas (PC) y mejor rendimiento (GPA).

**Consecuencia:**

$$\text{plim } \hat{\beta}_1^{\text{MCO}} = \beta_1 + \frac{\text{Cov}(\text{PC}, u)}{\text{Var}(\text{PC})} \neq \beta_1 \quad (7)$$

El estimador de MCO es **inconsistente** (sesgado incluso con  $n \rightarrow \infty$ ).

## 1.2. Ejercicio 1b: Ingreso parental como instrumento

**Condiciones para una Variable Instrumental válida  $z$ :**

1. **Relevancia (testeable):**

$$\text{Cov}(z_i, \text{PC}_i) \neq 0 \quad (8)$$

El instrumento debe estar correlacionado con la variable endógena.

2. **Exogeneidad/Restricción de exclusión (NO testeable):**

$$\text{Cov}(z_i, u_i) = 0 \quad (9)$$

El instrumento NO debe estar correlacionado con el error, excepto a través de su efecto sobre  $x$ .

**Evaluación del ingreso parental como IV para PC:**

Sea  $z_i = \text{ingreso\_parental}_i$

### 1. ¿Cumple RELEVANCIA?

$$\text{Cov}(\text{ingreso\_parental}_i, \text{PC}_i) > 0 \quad \checkmark \quad (10)$$

**SÍ cumple:** Familias con mayor ingreso tienen mayor probabilidad de comprar PCs. Podemos verificarlo con la regresión de primera etapa:

$$\text{PC}_i = \pi_0 + \pi_1(\text{ingreso\_parental}_i) + v_i \quad (11)$$

Esperamos que  $\pi_1 > 0$  y estadísticamente significativo.

### 2. ¿Cumple EXOGENEIDAD?

$$\text{Cov}(\text{ingreso\_parental}_i, u_i) \stackrel{?}{=} 0 \quad (12)$$

**NO cumple:** El ingreso parental afecta al GPA a través de múltiples canales:

$$\text{GPA}_i = \beta_0 + \beta_1 \text{PC}_i + \gamma_1 \text{tutorías}_i + \gamma_2 \text{libros}_i + \gamma_3 \text{ambiente}_i + \tilde{u}_i \quad (13)$$

donde todas las variables  $\text{tutorías}_i$ ,  $\text{libros}_i$ ,  $\text{ambiente}_i$  están en  $u_i$  y son afectadas por el ingreso parental:

$$\begin{aligned} \text{tutorías}_i &= f(\text{ingreso\_parental}_i) \\ \text{libros}_i &= f(\text{ingreso\_parental}_i) \\ \text{ambiente}_i &= f(\text{ingreso\_parental}_i) \end{aligned} \quad (14)$$

Por lo tanto:

$$\text{Cov}(\text{ingreso\_parental}_i, u_i) \neq 0 \quad \times \quad (15)$$

**Conclusión:**

El ingreso parental **NO** es un instrumento válido para PC porque:

✓ Cumple relevancia

× **NO** cumple exogeneidad

## 1.3. Ejercicio 1c: Grants aleatorios como Variable Instrumental

**Aleatorización como fuente de exogeneidad:**

Si una variable  $z$  se asigna de manera completamente aleatoria, entonces por construcción:

$$z_i \perp\!\!\!\perp u_i \quad \Rightarrow \quad \text{Cov}(z_i, u_i) = 0 \quad (16)$$

La aleatorización garantiza que  $z$  es independiente de todas las características observadas y no observadas.

**Construcción de la variable instrumental:**

Sea  $\text{GRANT}_i$  una variable binaria:

$$\text{GRANT}_i = \begin{cases} 1 & \text{si el estudiante } i \text{ recibió el apoyo hace 4 años} \\ 0 & \text{si el estudiante } i \text{ NO recibió el apoyo} \end{cases} \quad (17)$$

**¿Por qué GRANT es un buen instrumento?****1. EXOGENEIDAD (por aleatorización):**

Como los grants se asignaron **al azar**:

$$\text{GRANT}_i \perp\!\!\!\perp (u_i, \text{ability}_i, \text{family}_i, \dots) \Rightarrow \text{Cov}(\text{GRANT}_i, u_i) = 0 \quad \checkmark \quad (18)$$

**2. RELEVANCIA:**

Los estudiantes que recibieron el grant tienen mayor probabilidad de tener PC:

$$\text{Cov}(\text{GRANT}_i, \text{PC}_i) > 0 \quad \checkmark \quad (19)$$

Podemos verificarlo con la regresión de primera etapa:

$$\text{PC}_i = \pi_0 + \pi_1 \text{GRANT}_i + v_i \quad (20)$$

Esperamos que  $\pi_1 > 0$  y estadísticamente significativo.

**Estrategia de estimación:****Opción 1: Estimador de Wald (para instrumento binario)**

Dado que GRANT es binario, podemos usar:

$$\hat{\beta}_1^{\text{Wald}} = \frac{\overline{\text{GPA}}_1 - \overline{\text{GPA}}_0}{\overline{\text{PC}}_1 - \overline{\text{PC}}_0} \quad (21)$$

donde:

- $\overline{\text{GPA}}_1$  = GPA promedio del grupo con  $\text{GRANT} = 1$
- $\overline{\text{GPA}}_0$  = GPA promedio del grupo con  $\text{GRANT} = 0$
- $\overline{\text{PC}}_1$  = proporción con PC en el grupo con  $\text{GRANT} = 1$
- $\overline{\text{PC}}_0$  = proporción con PC en el grupo con  $\text{GRANT} = 0$

**Opción 2: Two-Stage Least Squares (2SLS)****Primera etapa:**

$$\text{PC}_i = \pi_0 + \pi_1 \text{GRANT}_i + v_i \quad (22)$$

Obtenemos los valores ajustados:

$$\widehat{\text{PC}}_i = \hat{\pi}_0 + \hat{\pi}_1 \text{GRANT}_i \quad (23)$$

**Segunda etapa:**

$$\text{GPA}_i = \beta_0 + \beta_1 \widehat{\text{PC}}_i + \varepsilon_i \quad (24)$$

El coeficiente  $\hat{\beta}_1$  de la segunda etapa es el estimador IV.

**Interpretación:**

$\hat{\beta}_1$  estima el **Local Average Treatment Effect (LATE)**:

$$\text{LATE} = E[\text{GPA}_i(1) - \text{GPA}_i(0) \mid \text{complier}_i] \quad (25)$$

donde los “compliers” son los estudiantes cuya decisión de tener PC fue afectada por recibir el grant.

## 2. EJERCICIO 2: Derivaciones del Estimador IV

### 2.1. Ejercicio 2a: Fórmula general del estimador IV

#### Modelo y supuestos:

Queremos estimar:

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (26)$$

Problema:  $\text{Cov}(x_i, u_i) \neq 0$  (endogeneidad)

Tenemos un instrumento  $z_i$  que satisface:

- **Exogeneidad:**  $\text{Cov}(z_i, u_i) = 0$
- **Relevancia:**  $\text{Cov}(z_i, x_i) \neq 0$

#### DERIVACIÓN DEL ESTIMADOR IV:

##### Paso 1: Partir de los momentos poblacionales

Multiplicamos el modelo por  $z_i$  y tomamos esperanza:

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_i + u_i \\ z_i \cdot y_i &= z_i \cdot \beta_0 + z_i \cdot \beta_1 x_i + z_i \cdot u_i \\ E[z_i y_i] &= E[z_i] \beta_0 + \beta_1 E[z_i x_i] + E[z_i u_i] \end{aligned} \quad (27)$$

##### Paso 2: Usar el supuesto de exogeneidad

Como  $\text{Cov}(z_i, u_i) = 0$ :

$$E[z_i u_i] = E[z_i] E[u_i] = 0 \quad (\text{porque } E[u_i] = 0) \quad (28)$$

Por lo tanto:

$$E[z_i y_i] = E[z_i] \beta_0 + \beta_1 E[z_i x_i] \quad (29)$$

Restando  $E[z_i] E[y_i]$  a ambos lados:

$$\begin{aligned} E[z_i y_i] - E[z_i] E[y_i] &= E[z_i] \beta_0 + \beta_1 E[z_i x_i] - E[z_i] [\beta_0 + \beta_1 E[x_i]] \\ \text{Cov}(z_i, y_i) &= \beta_1 [E[z_i x_i] - E[z_i] E[x_i]] \\ \text{Cov}(z_i, y_i) &= \beta_1 \text{Cov}(z_i, x_i) \end{aligned} \quad (30)$$

##### Paso 3: Despejar $\beta_1$

$$\boxed{\beta_1 = \frac{\text{Cov}(z_i, y_i)}{\text{Cov}(z_i, x_i)}} \quad (31)$$

##### Paso 4: Análogo muestral (estimador)

Usando el método de momentos, reemplazamos las covarianzas poblacionales por sus análogos muestrales:

$$\hat{\beta}_1^{\text{IV}} = \frac{\widehat{\text{Cov}}(z_i, y_i)}{\widehat{\text{Cov}}(z_i, x_i)} = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})} \quad (32)$$

**Propiedades del estimador:**

1. **Consistencia:**

$$\text{plim}_{n \rightarrow \infty} \hat{\beta}_1^{\text{IV}} = \beta_1 \quad (33)$$

2. **Insesgamiento asintótico:**

$$\lim_{n \rightarrow \infty} E[\hat{\beta}_1^{\text{IV}}] = \beta_1 \quad (34)$$

3. **Distribución asintótica:**

$$\sqrt{n}(\hat{\beta}_1^{\text{IV}} - \beta_1) \xrightarrow{d} N(0, V) \quad (35)$$

donde  $V$  depende de la correlación entre  $z$  y  $x$ .

## 2.2. Ejercicio 2b: Estimador de Wald para instrumento binario

### Caso especial: Instrumento binario

Cuando el instrumento  $z_i$  es una variable binaria ( $z_i \in \{0, 1\}$ ), el estimador IV se simplifica considerablemente.

**OBJETIVO:** Mostrar que cuando  $z_i$  es binario:

$$\hat{\beta}_1^{\text{IV}} = \frac{\bar{y}_1 - \bar{y}_0}{\bar{x}_1 - \bar{x}_0} \quad (36)$$

donde:

- $\bar{y}_1 = \frac{1}{n_1} \sum_{i: z_i=1} y_i$  (promedio de  $y$  para  $z = 1$ )
- $\bar{y}_0 = \frac{1}{n_0} \sum_{i: z_i=0} y_i$  (promedio de  $y$  para  $z = 0$ )
- $\bar{x}_1, \bar{x}_0$  definidos similarmente
- $n_1 = \sum_i \mathbb{1}(z_i = 1)$ ,  $n_0 = \sum_i \mathbb{1}(z_i = 0)$

### DERIVACIÓN:

**Paso 1: Calcular  $E[z_i]$  cuando  $z$  es binaria**

Sea  $p = P(z_i = 1)$ . Entonces:

$$E[z_i] = 0 \cdot P(z_i = 0) + 1 \cdot P(z_i = 1) = p \quad (37)$$

En la muestra:

$$\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i = \frac{n_1}{n} \quad (38)$$

**Paso 2: Calcular  $\text{Cov}(z_i, y_i)$**

$$\begin{aligned} \text{Cov}(z_i, y_i) &= E[z_i y_i] - E[z_i]E[y_i] \\ &= E[y_i \mid z_i = 1] \cdot P(z_i = 1) - p \cdot E[y_i] \end{aligned} \quad (39)$$

Expandiendo  $E[y_i]$ :

$$E[y_i] = E[y_i \mid z_i = 1]P(z_i = 1) + E[y_i \mid z_i = 0]P(z_i = 0) \quad (40)$$

Sustituyendo:

$$\begin{aligned} \text{Cov}(z_i, y_i) &= p \cdot E[y_i \mid z_i = 1] - p[p \cdot E[y_i \mid z_i = 1] + (1 - p) \cdot E[y_i \mid z_i = 0]] \\ &= p \cdot E[y_i \mid z_i = 1] - p^2 \cdot E[y_i \mid z_i = 1] - p(1 - p) \cdot E[y_i \mid z_i = 0] \\ &= p(1 - p) \cdot E[y_i \mid z_i = 1] - p(1 - p) \cdot E[y_i \mid z_i = 0] \\ &= p(1 - p)[E[y_i \mid z_i = 1] - E[y_i \mid z_i = 0]] \end{aligned} \quad (41)$$

En la muestra, con  $p = n_1/n$ :

$$\widehat{\text{Cov}}(z_i, y_i) = \frac{n_1}{n} \left(1 - \frac{n_1}{n}\right) (\bar{y}_1 - \bar{y}_0) = \frac{n_1 n_0}{n^2} (\bar{y}_1 - \bar{y}_0) \quad (42)$$

**Paso 3: Calcular  $\text{Cov}(z_i, x_i)$  de manera similar**

Por el mismo razonamiento:

$$\widehat{\text{Cov}}(z_i, x_i) = \frac{n_1 n_0}{n^2} (\bar{x}_1 - \bar{x}_0) \quad (43)$$

**Paso 4: Sustituir en la fórmula del estimador IV**

$$\begin{aligned} \hat{\beta}_1^{\text{IV}} &= \frac{\widehat{\text{Cov}}(z_i, y_i)}{\widehat{\text{Cov}}(z_i, x_i)} \\ &= \frac{\frac{n_1 n_0}{n^2} (\bar{y}_1 - \bar{y}_0)}{\frac{n_1 n_0}{n^2} (\bar{x}_1 - \bar{x}_0)} \\ &= \boxed{\frac{\bar{y}_1 - \bar{y}_0}{\bar{x}_1 - \bar{x}_0}} \end{aligned} \quad (44)$$

Esto es el estimador de Wald.

## 2.3. Interpretación del estimador de Wald

**FORMA INTUITIVA:**



$$\hat{\beta}_1^{\text{Wald}} = \frac{\text{Diferencia en } y \text{ entre grupos}}{\text{Diferencia en } x \text{ entre grupos}} = \frac{\text{Forma reducida}}{\text{Primera etapa}} \quad (45)$$

**Componentes:**

**1. Forma reducida (Reduced Form):**

$$\bar{y}_1 - \bar{y}_0 = \text{Efecto total del instrumento sobre el resultado} \quad (46)$$

**2. Primera etapa (First Stage):**

$$\bar{x}_1 - \bar{x}_0 = \text{Efecto del instrumento sobre el tratamiento} \quad (47)$$

**Conexión con 2SLS:**

El estimador de Wald es equivalente a Two-Stage Least Squares:

**Etapas 1:**

$$x_i = \pi_0 + \pi_1 z_i + v_i \quad (48)$$

Cuando  $z$  es binario:

$$\hat{\pi}_1 = \bar{x}_1 - \bar{x}_0 \quad (49)$$

Los valores ajustados son:

$$\hat{x}_i = \begin{cases} \bar{x}_1 & \text{si } z_i = 1 \\ \bar{x}_0 & \text{si } z_i = 0 \end{cases} \quad (50)$$

**Etapas 2:**

$$y_i = \beta_0 + \beta_1 \hat{x}_i + \varepsilon_i \quad (51)$$

El coeficiente de esta regresión es exactamente el estimador de Wald.

## 2.4. Aplicación al Ejercicio 1c

**Aplicación a los grants aleatorios:**

En el contexto del Ejercicio 1c, donde:

- $y_i = \text{GPA}_i$
- $x_i = \text{PC}_i$
- $z_i = \text{GRANT}_i$

El estimador de Wald se convierte en:

$$\hat{\beta}_1^{\text{Wald}} = \frac{\overline{\text{GPA}}_{\text{grant}=1} - \overline{\text{GPA}}_{\text{grant}=0}}{\overline{\text{PC}}_{\text{grant}=1} - \overline{\text{PC}}_{\text{grant}=0}} \quad (52)$$

### Interpretación:

- **Numerador:** Diferencia en GPA promedio entre quienes recibieron el grant y quienes no.
- **Denominador:** Diferencia en la proporción con PC entre quienes recibieron el grant y quienes no.
- **Cociente:** Efecto causal de tener una PC sobre el GPA (para los compliers).

### Ejemplo numérico:

Supongamos que encontramos:

- $\overline{\text{GPA}}_{\text{grant}=1} = 3,2$
- $\overline{\text{GPA}}_{\text{grant}=0} = 3,0$
- $\overline{\text{PC}}_{\text{grant}=1} = 0,8$  (80 % tienen PC)
- $\overline{\text{PC}}_{\text{grant}=0} = 0,4$  (40 % tienen PC)

Entonces:

$$\hat{\beta}_1^{\text{Wald}} = \frac{3,2 - 3,0}{0,8 - 0,4} = \frac{0,2}{0,4} = 0,5 \quad (53)$$

**Interpretación:** Tener una PC aumenta el GPA en 0.5 puntos, en promedio, para los estudiantes cuya decisión de tener PC fue afectada por recibir el grant.

## 3. Resumen de conceptos clave

### CONCEPTOS FUNDAMENTALES:

1. **Endogeneidad:**  $\text{Cov}(x, u) \neq 0 \Rightarrow \text{MCO es inconsistente}$

2. **Variable Instrumental válida:**

- Relevancia:  $\text{Cov}(z, x) \neq 0$
- Exogeneidad:  $\text{Cov}(z, u) = 0$

3. **Estimador IV general:**

$$\hat{\beta}_1^{\text{IV}} = \frac{\text{Cov}(z, y)}{\text{Cov}(z, x)}$$

4. **Estimador de Wald (z binario):**

$$\hat{\beta}_1^{\text{Wald}} = \frac{\bar{y}_1 - \bar{y}_0}{\bar{x}_1 - \bar{x}_0}$$

5. **2SLS:**

- Etapa 1:  $\hat{x} = \hat{\pi}_0 + \hat{\pi}_1 z$
- Etapa 2:  $y = \hat{\beta}_0 + \hat{\beta}_1 \hat{x} + \varepsilon$

6. **LATE:** IV identifica el efecto para “compliers”